



Abschlussprojekt Angewandtes Maschinelles Lernen

Krystian Gluc - 12230903
Cristian Grigore - 12312344
Dominik Berghammer - 12316294
Adrian Linder - 12243106

8. Januar 2026, Vienna

Inhaltsverzeichnis

1 Thema	2
2 Technologien	2
3 Das Ausfüllen von Lückentexten	3
3.1 Einfaches Ausfüllen mithilfe von BERT	3
3.2 Verschiedene Modelle für Verschiedene Themengebiete	4
4 Finetune Beispiel mit BERT	5
4.1 Dataset	5
4.2 Training	6
4.3 Auswertung	8
5 Korrektur von Lückentexten	10
5.1 Datenset für Korrektur	10
5.2 Korrektur mit BERT	11

1 Thema

Nach unserem ersten Versuch allgemeiner angelegte Methoden zur Textgenerierung zu bewerten und von Scratch zu trainieren, haben wir uns auf eine spezifischere Aufgabe fokussiert: Masked-Language-Models und Lückentexte. Zu diesem Thema wurden dann drei verschiedene Aufgaben spezifiziert:

1. Das Ausfüllen von Lückentexten
2. Das Finetunen von MLMs
3. Das Korrigieren von Lückentexten

2 Technologien

Bei einer Recherche zu diesem Thema stößt man schnell auf den Begriff Masked-Language-Models. Eines der bekanntesten Modelle dazu ist BERT (Bidirectional Encoder Representations from Transformers). Es gibt auch zahlreiche andere Modelle, die für Lückentexte verwendet werden können. Einige Beispiele hierzu wären BART, RoBERTa, ALBERT, ELECTRA, MPNet wobei hinter vielen von diesen Modellen die BERT Architektur steckt. Wenn man solch einem Modell einen maskierten Text gibt, antwortet dieses mit dem Wort, das sich am wahrscheinlichsten hinter der Maske versteckt.

Bei dem Satz "[MASK] is the capital of France." würde so ein Modell zum Beispiel das Wort "Paris" vorhersagen.

3 Das Ausfüllen von Lückentexten

3.1 Einfaches Ausfüllen mithilfe von BERT

Eine der einfachsten Möglichkeiten, einen Lückentext automatisch auszufüllen, ist die Verwendung von BERT über die *transformers*-Bibliothek.

```
1 from transformers import pipeline
2
3 pipeline_bert = pipeline(
4     task="fill-mask",
5     model="bert-base-uncased",
6     device=0 # benutzt GPU statt CPU
7 )
8 pipeline_bert(
9     "Plants create [MASK] through a process [MASK] as photosynthesis.",
10    top_k=2 # gibt die Top 2 Resultate zurück
11 )
12 )
```

Nachdem man diesen Code ausführt, erhält man folgendes Resultat.

```
1 [
2     [{'score': 0.2662782669067383,
3      'token': 2943,
4      'token_str': 'energy',
5      'sequence': '[CLS] plants create energy through a process [MASK] as
6      photosynthesis. [SEP]'}],
7     {'score': 0.10305079817771912,
8      'token': 4870,
9      'token_str': 'flowers',
10     'sequence': '[CLS] plants create flowers through a process [MASK] as
11     photosynthesis. [SEP]'}],
12     [{'score': 0.9980964064598083,
13      'token': 2124,
14      'token_str': 'known',
15      'sequence': '[CLS] plants create [MASK] through a process known as
16      photosynthesis. [SEP]'}],
17     {'score': 0.001142986468039453,
18      'token': 2107,
19      'token_str': 'such',
20      'sequence': '[CLS] plants create [MASK] through a process such as
21      photosynthesis. [SEP]'}],
22 ]
```

Da der Lückentext zwei Lücken enthält, bekommt man eine Liste mit zwei Resultaten zurück. Dies sind jeweils die zwei Vorschläge für Lücke 1 und Lücke 2.

Anhand des Scores ist sofort ersichtlich, dass sich das Modell bei der zweiten Lücke deutlich sicherer fühlt als bei der ersten Lücke.

Das Modell schlägt uns also den folgenden ausgefüllten Lückentext vor:

*Plants create **energy** through a process **known** as photosynthesis.*

3.2 Verschiedene Modelle für Verschiedene Themengebiete

4 Finetune Beispiel mit BERT

Im folgenden Kapitel werden wir uns nun mit einem Anwendungsbeispiel beschäftigen welches ein BERT Modell nutzt um Informationen für Nutzer bereitzustellen.

Wir wollen nun BERT nutzen um einem Benutzer die Möglichkeit zu geben durch Natürliche Fragen Informationen über eine Fiktive Firma zu erhalten. Daher betrachten wir nun einmal unser Trainingsset

4.1 Dataset

Wir betrachten die Fiktive Firma *Example Tech* mit Standorten in Berlin, München und Hamburg. Wir haben nun eine Liste von Mitarbeitern welche in bestimmten Positionen an bestimmten Orten arbeiten

```
1  {
2      "name": "Alice",
3      "role": "CEO",
4      "location": "Berlin",
5      "email": "ceo@exampletech.com"
6  },
7  {
8      "name": "Carol",
9      "role": "CFO",
10     "location": "Munich",
11     "email": "cfo@exampletech.com"
12 },
13 {
14     "name": "Lily",
15     "role": "Accountant",
16     "location": "Hamburg",
17     "email": "accounting.hamburg@exampletech.com"
18 },
19 ....
```

Insgesamt gibt es 24 Personen mit verschiedenen Jobs, Namen und Arbeitsorten. Weiters bietet das Unternehmen noch verschiedene Produkte an

```
1  {
2      "name": "AlphaPhone",
3      "category": "Electronics",
4      "price": 699
5  },
6  {
7      "name": "OrionERP",
8      "category": "Software",
9      "price": 99
10 },
11 {
12     "name": "LightPanel",
13     "category": "Furniture",
14     "price": 149
15 },
16 {
17     "name": "TechSupport+",
18 }
```

```

19         "category": "Service",
20         "price": 39
21     },
22     ....

```

Es gibt gesamt 19 Produkte.

Nun können wir uns Fragen wie wir dieses Datenset in eine Form überführen mit welcher wir BERT trainieren können. Die Idee war nun dies mittels Natürlicher Fragen über das Datenset zu machen. Wir trainieren also auf Text wie

Alice is the CEO working in the Berlin Office

oder

Alice's email address is ceo@exampletech.com

und auch Fragen wie

Where is Alice? In the Berlin Office.

Selbes machen wir für die Produkte. Würden wir nun diese Fragen einfach dem Tokenizer geben hätten wir jedoch ein Problem. Denn z.B. CEO ist *Ein* Token jedoch z.B. Sales Manager *zwei* Token und eine EMail adresse wird sogar in bis zu *fünf* Token aufgespaltet. Daher unsere Lösung, wir fügen einfach einige neue Token hinzu. Dies lässt sich mittels Transformerers sehr einfach machen.

```

1 emails = [
2     e["email"] for e in json.load(open("dataset.json"))["employees"]
3 ]
4
5
6 jobs = [
7     e["role"] for e in json.load(open("dataset.json"))["employees"]
8 ]
9
10
11 products = [
12     e["name"] for e in json.load(open("dataset.json"))["products"]
13 ]
14
15
16 prices = [
17     str(e["price"]) for e in json.load(open("dataset.json"))["products"]
18 ]
19
20 companyName = [json.load(open("dataset.json"))["company"]["name"]]
21 ]
22
23 tokenizer.add_tokens(emails)
24 tokenizer.add_tokens(jobs)
25 tokenizer.add_tokens(products)
26 tokenizer.add_tokens(prices)
27 tokenizer.add_tokens(companyName)
28
29 # WICHTIG Model auf neues Vokabular anpassen
30 model.resize_token_embeddings(len(tokenizer))

```

4.2 Training

Das Training wird lokal mittels PyTorch und Transformerers durchgeführt. Der genutzte PC hat die folgenden Spezifikationen

CPU	AMD Ryzen 7 7700X
GPU	NVIDIA GeForce RTX 3060 12GB
RAM	32 GB - DDR5 4800 MT/s
Betriebssystem	Arch Linux - 6.18.2
CUDA	12.6

Die Transformerers Bibliothek hat glücklicherweise bereits eine Implementation für BERT somit können wir diese einfach nutzen. Zunächst importieren wir den Tokenizer und das Model sowie den Trainer.

```
1 import torch
2 from transformers import (
3     BertTokenizer,
4     BertForMaskedLM,
5     DataCollatorForLanguageModeling,
6     Trainer,
7     TrainingArguments,
8     EarlyStoppingCallback)
```

damit ist schon fast die Hälfte des Coding Aufwands geschafft.

Unsere nächste Überlegung ist nun welches Model wir nutzen wollen zum Trainieren. Unsere Wahl fiel auf *bert-base-uncased*. Dieses ist ein Basis BERT Model welche nicht zwischen Groß- und Kleinschreibung unterscheidet. Wie bereits vorher diskutiert wurden dem Tokenizer die EMail-Adressen, Jobs und Produkte als Token hinzugefügt damit wir uns nicht über die genaue Anzahl an Mask gedanken machen müssen. Um nun das Model und den Tokenizer zu laden können wir einfach Transformerers nutzen

```
1 model = BertForMaskedLM.from_pretrained("bert-base-uncased")
2 tokenizer = BertTokenizer.from_pretrained("bert-base-uncased")
```

Transformerers wird uns nun automatisch das Model herunterladen und lokal speichern. Dies kann beim ersten Start zu einiger Wartezeit führen je nach Internetvertrag.

Wir wollen nun den Trainer vorbereiten. Hierzu nutzen wir die *TrainingArguments*. Wir nutzen hierbei die folgenden Argumente:

Argument	Wert	Beschreibung
num_train_epochs	500	Anzahl der Epochen (wie oft durch das gesamte Trainingsset durchgegangen wird)
per_device_train_batch_size	16	Die Batch Größe
learning_rate	5e-5(10 ⁻⁵)	Lernrate
save_steps	3000	Wie oft er einen Zwischenstand speichert
save_total_limit	2	Wie viele Zwischenstände er behält
logging_steps	100	Wie oft der Loss berechnet und ausgegeben wird
lr_scheduler_type	linear	Wie die Lernrate verändert wird
warmup_ratio	0.1	

Nun können wir also mit diesen Argumenten einen Trainer erstellen.

```
1 training_args = TrainingArguments(
2     #Arguments
3 )
4
5 trainer = Trainer(
6     model=model,
7     args=training_args,
8     train_dataset=dataset,
9     data_collator=data_collator,
10 )
```

Nun sind wir endlich bereit den Trainer zu starten. Dies ist simple und einfach. Anschließend können wir das Model noch speichern damit wir es später verwenden können.

```
1 trainer.train()  
2  
3 model.save_pretrained("./bert-company")  
4 tokenizer.save_pretrained("./bert-company")
```

4.3 Auswertung

Das Training dauert ca. 15 Minuten auf dem oben angeführten PC. Nach Abschluss ist nun die Frage wie Werten wir den Finetune aus? Hierzu wurden verschiedene Fragen für jedes gelernte Datum gestellt, welche nicht zum Training genutzt wurden. Die Fragen lauten wie folgt

name works in [MASK].

The email address [MASK] belongs to name.

Who is role in location? [MASK].

product-name sales for [MASK] euros.

Diese Fragen wurden nun für jede Person/Produkt ausgewertet und BERT gegeben. Das Ergebnis lautet wie folgt:

Correct: 98/101

Accuracy: 97.02970297029702%

Von 101 Fragen wurden also 98 richtig beantwortet. Welche führten nun zu Probleme?

Input: Who is CFO in Munich? [MASK].

Output: who is cfo in munich? cfo@exampletech.com.

Correct: who is cfo in munich? carol.

Input: Who is Marketing Specialist in Munich? [MASK].

Output: who is marketing specialist in munich? marketing.munich@exampletech.com.

Correct: who is marketing specialist in munich? nathan.

Input: Who is Customer Support in Hamburg? [MASK].

Output: who is customer support in hamburg? customer@exampletech.com.

Correct: who is customer support in hamburg? lana.

Wir sehen das in allen drei Fällen der Name mit einer Email verwechselt wurde. Betrachten wir für jede dieser Fragen die 5 Wahrscheinlichsten Token so sehen wir

Input: Who is CFO in Munich? [MASK].

cfo@exampletech.com (p=0.6099)

carol (p=0.3184)

cfo (p=0.0324)

munich (p=0.0098)

hr.munich@exampletech.com (p=0.0063)

Input: Who is Marketing Specialist in Munich? [MASK].

marketing.munich@exampletech.com (p=0.4459)

nathan (p=0.3087)

marketing specialist (p=0.0701)

hr.munich@example.tech.com (p=0.0401)
munich (p=0.0349)

Input: Who is Customer Support in Hamburg? [MASK].

customer@example.tech.com (p=0.6026)
lana (p=0.2535)
customer support (p=0.0983)
hamburg (p=0.0061)
it@example.tech.com (p=0.0051)

Jedes Mal ist die richtige Antwort die zweit Wahrscheinlichste und das mit einem nicht zu vernachlässigen Prozentsatz. Wir können nun einmal betrachten wie es bei den richtigen Antworten aussieht. Die Fragen mit den geringsten Wahrscheinlichkeitswerten sind die folgenden

57.04% | Who is HR Assistant in Hamburg? [MASK].
59.45% | Who is Support Lead in Berlin? [MASK].
64.54% | Who is HR Manager in Berlin? [MASK].
71.19% | Who is HR Assistant in Munich? [MASK].
78.07% | Who is IT Director in Hamburg? [MASK].

Generell lässt sich die Wahrscheinlichkeit(Confidence) im folgenden Diagramm darstellen.




Abbildung 1: Confidence des BERT-Finetune

Wir sehen also bei einem Großteil der Vorhersagen ist sich das Modell sehr sicher. 86 von 98 Vorhersagen haben eine Sicherheit von mehr als 95 % und lediglich 5 eine kleiner als 80 %. Dennoch sehen wir das Modell ist vor allem bei Fragen etwas unsicher. Somit wäre ein Training mit etwas mehr Fragen sicherlich hilfreich um die Sicherheit weiter zu stärken.

5 Korrektur von Lückentexten

In diesem Teil wollten wir einem Modell einen ausgefüllten Lückentext geben, damit es ihn korrigiert: Wurde der Text richtig oder falsch ausgefüllt?

5.1 Datenset für Korrektur

Zunächst wurde hier ein öffentliches Datenset "Cloze-test-with-Bert"¹ verwendet. Dieses besteht aus einem Test- und einem Trainingsset, wobei das Testset 1.267 und das Trainingsset 40.398 Sätze mit jeweils zwei Antwortmöglichkeiten beinhaltet. Eine Datei aus dem Datenset sieht z.B. so aus:

```
1 {
2   "qID": "3FBFUUYRMJQCIM5XJOW8CIQYEGA6Z-1",
3
4   "sentence": "Jane received a pet tortoise and an aquarium as a
   birthday gift, but the _ was too small.",
5
6   "option1": "aquarium",
7
8   "option2": "tortoise",
9
10  "answer": "1"
11 }
```

Um das Datenset gut benutzen zu können haben wir es mithilfe Python transformiert:

```
1 input_file = "./test.jsonl"
2 output_file = "./testnew.jsonl" #oder "./train.jsonl" und "./trainnew.jsonl"
3
4 with open(input_file, "r", encoding="utf-8") as fin, \
5     open(output_file, "w", encoding="utf-8") as fout:
6
7     for line in fin:
8         data = json.loads(line)
9
10        sentence = data["sentence"]
11        masked_sentence = sentence.replace("_", "[MASK]") #da BERT [MASK] braucht
12        opt1 = data["option1"]
13        opt2 = data["option2"]
14        correct = data["answer"] # "1" oder "2"
15
16        filled_1 = sentence.replace("_", opt1) # Option 1 einsetzen
17        example_1 = {
18            "qID": data["qID"],
19            "unfilled_sentence": masked_sentence,
20            "filled_sentence": filled_1,
21            "chosen_option": opt1,
22            "is_correct": correct == "1"
23        }
24
25        filled_2 = sentence.replace("_", opt2) # Option 2 einsetzen
26        example_2 = {
27            "qID": data["qID"],
28            "unfilled_sentence": masked_sentence,
29            "filled_sentence": filled_2,
```

¹<https://github.com/TheMaxi7/Cloze-test-with-BERT>

```

30         "chosen_option": opt2,
31         "is_correct": correct == "2"
32     }
33
34     fout.write(json.dumps(example_1, ensure_ascii=False) + "\n")
35     fout.write(json.dumps(example_2, ensure_ascii=False) + "\n")

```

Dieser Code bringt das Datenset in eine Form, die für unsere Anwendung besser ist. Jede Datei wird aufgeteilt in zwei Dateien. Die obere Beispieldatei wird auf zwei Dateien aufgeteilt:

```

1  {
2      "qID": "3FBEFUUYRMJCQIM5XJ0W8CIQYEGA6Z-1",
3
4      "unfilled_sentence": "Jane received a pet tortoise and an aquarium
as a birthday gift, but the [MASK] was too small.",
5
6      "filled_sentence": "Jane received a pet tortoise and an aquarium as
a birthday gift, but the aquarium was too small.",
7
8      "chosen_option": "aquarium",
9
10     "is_correct": true
11 }
12
13 {
14     "qID": "3FBEFUUYRMJCQIM5XJ0W8CIQYEGA6Z-1",
15
16     "unfilled_sentence": "Jane received a pet tortoise and an aquarium
as a birthday gift, but the [MASK] was too small.",
17
18     "filled_sentence": "Jane received a pet tortoise and an aquarium as
a birthday gift, but the tortoise was too small.",
19
20     "chosen_option": "tortoise",
21
22     "is_correct": false
23 }

```

5.2 Korrektur mit BERT

Zuerst versuchen wir den Text mit einem vortrainierten BERT-Modell zu korrigieren. Wir machen dies, indem wir die Funktion `token_probability` definieren, die einen Satz mit [MASK]-Token tokenized, die Position des [MASK]-Tokens findet, Logits an der Maskenposition auswählt und dann die Logits mittels Softmax in Wahrscheinlichkeiten umwandelt. Das eingesetzte Wort wird von ihr auch tokenized, wobei ein `ValueError` ausgegeben wird, falls das Wort aus mehr als einem Token besteht, um sie später einfach überspringen zu können, da BERT nur einzelne Tokens bewerten kann. Die Funktion gibt am Ende die bedingte Wahrscheinlichkeit aus, dass das Modell den Token vom eingesetzten Wort an der Maskenposition vorhersagt.

Danach wird für jeden Satz in jeder Zeile der jsonl-Datei mithilfe von `token_probability` die bedingte Wahrscheinlichkeit berechnet, außer sie wird übersprungen, da das eingesetzte Wort aus mehreren Tokens besteht. Schließlich geben wir die Anzahl der verwendeten und übersprungenen Sätze an.

Um einen guten Threshold zu finden, ab welcher Wahrscheinlichkeit wir sagen, dass der Satz korrekt ausgefüllt wurde, nehmen wir 300 Werte zwischen dem kleinsten und größten Wahrscheinlichkeit. Für jeden

dieser Wahrscheinlichkeitswerte schauen wir uns an welche Wörter eine höhere Wahrscheinlichkeit haben und überprüfen wie viele davon korrekt sind. Der Threshold mit den meisten richtigen Vorhersagen wird als bester Threshold ausgegeben, zusammen mit der Accuracy unter diesem Threshold.

```
1 import json
2 import torch
3 import numpy as np
4 from transformers import BertTokenizer, BertForMaskedLM
5 import torch.nn.functional as F
6
7 model_name = "bert-base-uncased"
8 tokenizer = BertTokenizer.from_pretrained(model_name)
9 model = BertForMaskedLM.from_pretrained(model_name)
10 model.eval()
11
12 device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
13 model.to(device)
14
15 print("Running on:", device)
16
17 input_file = "./trainnew.jsonl"
18
19 scores = [] # p(w | context)
20 labels = [] # is_correct
21 skipped = 0
22
23
24 def token_probability(masked_sentence, word):
25     inputs = tokenizer(masked_sentence, return_tensors="pt").to(device)
26
27     mask_index = torch.where(
28         inputs["input_ids"] == tokenizer.mask_token_id
29     )[1]
30
31     with torch.no_grad():
32         outputs = model(**inputs)
33         logits = outputs.logits
34
35     mask_logits = logits[0, mask_index, :]
36     probs = F.softmax(mask_logits, dim=-1)
37
38     token_ids = tokenizer.convert_tokens_to_ids(
39         tokenizer.tokenize(word)
40     )
41
42     if len(token_ids) != 1:
43         raise ValueError
44
45     return probs[0, token_ids[0]].item()
46
47
48 #Scores sammeln
49
50 with open(input_file, "r", encoding="utf-8") as fin:
51     for line in fin:
52         data = json.loads(line)
53
54         masked_sentence = data["unfilled_sentence"]
55         chosen_option = data["chosen_option"]
56         is_correct_label = data["is_correct"]
57
58         try:
59             p = token_probability(masked_sentence, chosen_option)
60         except ValueError:
```

```
61         skipped += 1
62         continue
63
64         scores.append(p)
65         labels.append(is_correct_label)
66
67     scores = np.array(scores)
68     labels = np.array(labels)
69
70     print(f"Verwendete Samples: {len(scores)}")
71     print(Uebersprungene Samples: {skipped})
72
73
74     #Optimalen Threshold finden
75
76     best_acc = 0.0
77     best_threshold = 0.0
78
79     for t in np.linspace(scores.min(), scores.max(), 300):
80         preds = scores > t
81         acc = (preds == labels).mean()
82         if acc > best_acc:
83             best_acc = acc
84             best_threshold = t
85
86     print(f"Best Threshold: {best_threshold:.6f}")
87     print(f"Best Accuracy: {best_acc * 100:.2f}%")
```

Der Code gibt auf dem "Trainingsset"folgendes Resultat aus:

```
Running on: cuda
Verwendete Samples: 74644
Übersprungene Samples: 6152
Best Threshold: 0.056660
Best Accuracy: 52.62%
```

Man sieht, dass die Accuracy auch mit dem besten Threshold nur etwas mehr als 50% beträgt, d.h. dass das Modell kaum besser als Raten ist.

Warum passiert das?